证据链上，人该先审哪一项?

STA3145 强化学习 · 小组提案（开会用）
数据：与 Maia ten Brink（Stanford Psychophysiology Lab）一年 EMA 合作
应用：SciForge（Zhangyang Gao 开发，AI4Science, Shanghai AI Lab）
2026–11–09 · 5 人小组

中文

我们要做什么

AI 已经在帮实验室洗睡眠日记、标文献、跑分析。它产出的一条条结果**互相依赖**：时间写反了，睡眠潜伏期就错，睡眠效率就错，结论就不可信。

人不可能全查。我们用强化学习学一个**只读建议器**：下一步该审哪个节点，让更少的错误走到结论。

机器不盖章　只读排序　人点裁决才有收据

数学骨架（RL 课的主菜）

1. 因果传播（DAG 上的干预）

节点真实状态 $X_v \in \{0,1\}$（1=正确）。沿边 (u,v)：

$$P(X_v = 0 \mid X_u = 0) = 1 - \exp(-\lambda\, w_{uv}), \quad w_{uv} \sim U(0.5, 1.5),\ \lambda = 0.8$$

审节点 v = do$(X_v := 1)$，切断出边传染。**这是因果干预，不是相关。**

2. MDP

$\mathcal{S}$ = 图知识（type, conf, 下游影响, 已审否）+ 剩余预算；$\mathcal{A}$ = 选下一个节点（或 stop）；$\mathcal{P}$ = 审后重算下游；$r_T = -\#\text{sink errors}$；$\gamma < 1$。

3. CMDP 拉格朗日（预算不是倒计时）

$$\max_{\pi} \min_{\lambda \geq 0} J(\pi) + \lambda\,(B - C(\pi))$$

主方法现在是 GNN + 固定预算 REINFORCE；CMDP 双 critic 在做。

4. 次模贪心 (1−1/e)

选最能让可达 sink 错误下降的审阅是单调次模最大化。贪心保证最优干预集的 63%。N=500 上这个贪心把无标度图 81→3.8。

5. 信息增益奖励（设计里，还没跑）

$$R = \alpha\,\Delta H_v - \beta\,\mathrm{Cost}(v)$$

6. 策略梯度（主方法）

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_\pi\big[\nabla_\theta \log \pi_\theta(a_t \mid s_t)\, A_t\big], \quad A_t = G_t - b(s_t)$$

GNN 打分器：$h_v = \tanh\!\big(W_{\text{self}} x_v + W_{\text{neigh}} \frac{1}{|N(v)|} \sum_{u \in N(v)} x_u\big)$

7. 可靠性 worst-of-n

一个漏审能作废结论（HealthBench）。noise worst-of-5 = 5.20，oracle = 0.80。

为什么这不是编的

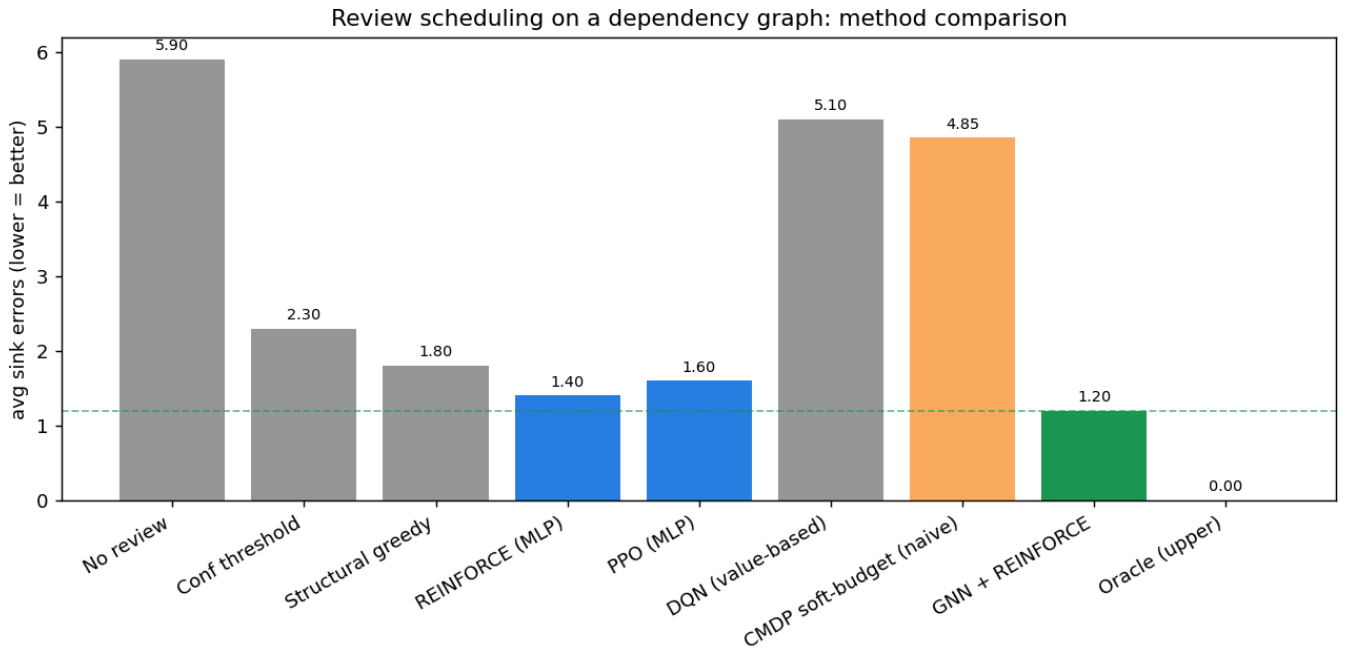
我们自己的数据：**13,990 条 / 237 人**，人改了 **75 处**（0.54%）。这 75 处里 **76% 是同一种错**（order_error，p<0.0001）。

错误率低，所以全审不划算；错误高度聚集，所以「审哪个」比「审多少」重要。

我们已经跑出来的（AI 生成，待组员复现）

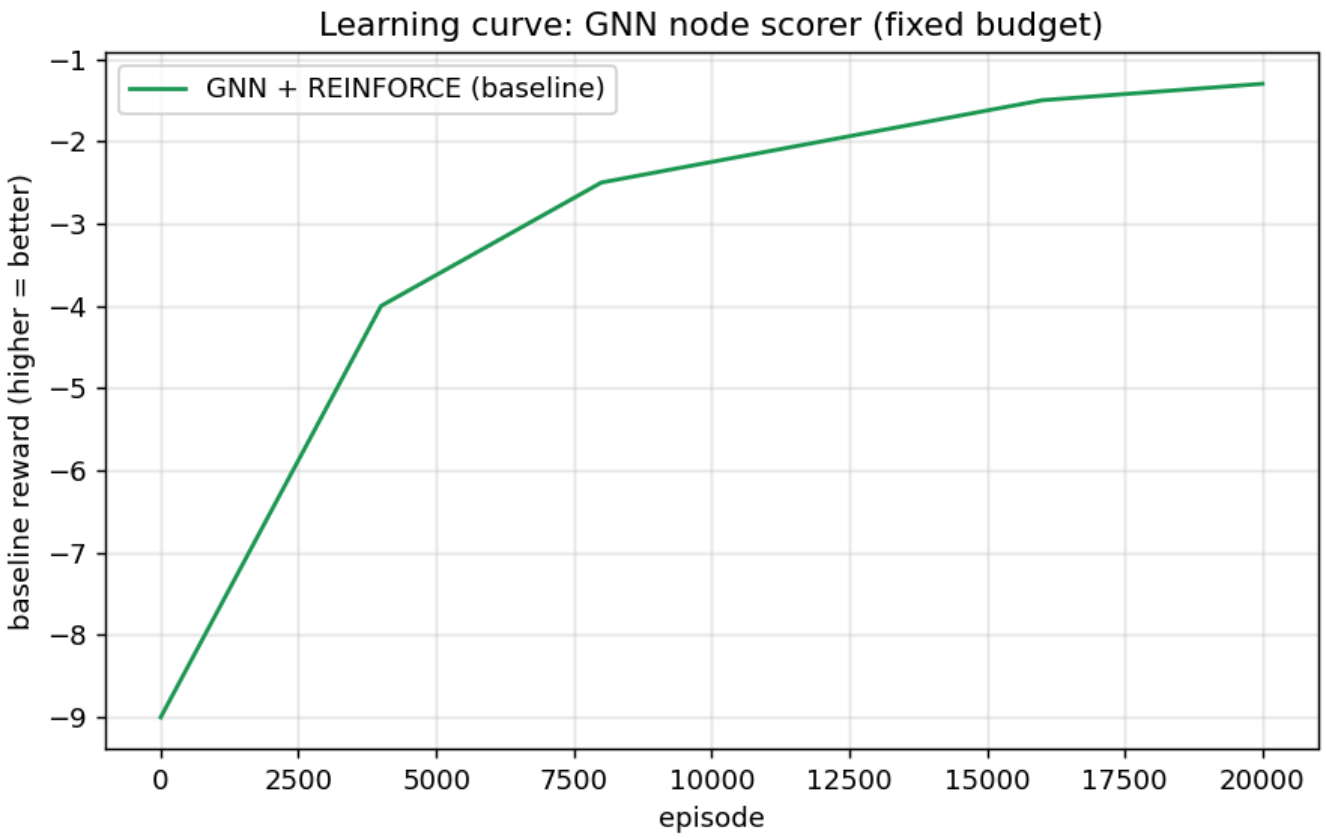
第一版做成逐条 bandit，**输给了阈值**（2.81 vs Q-learning 3.38）。诊断：把依赖图压平了，RL 没东西可学。

重构成「图上主动选节点」之后：

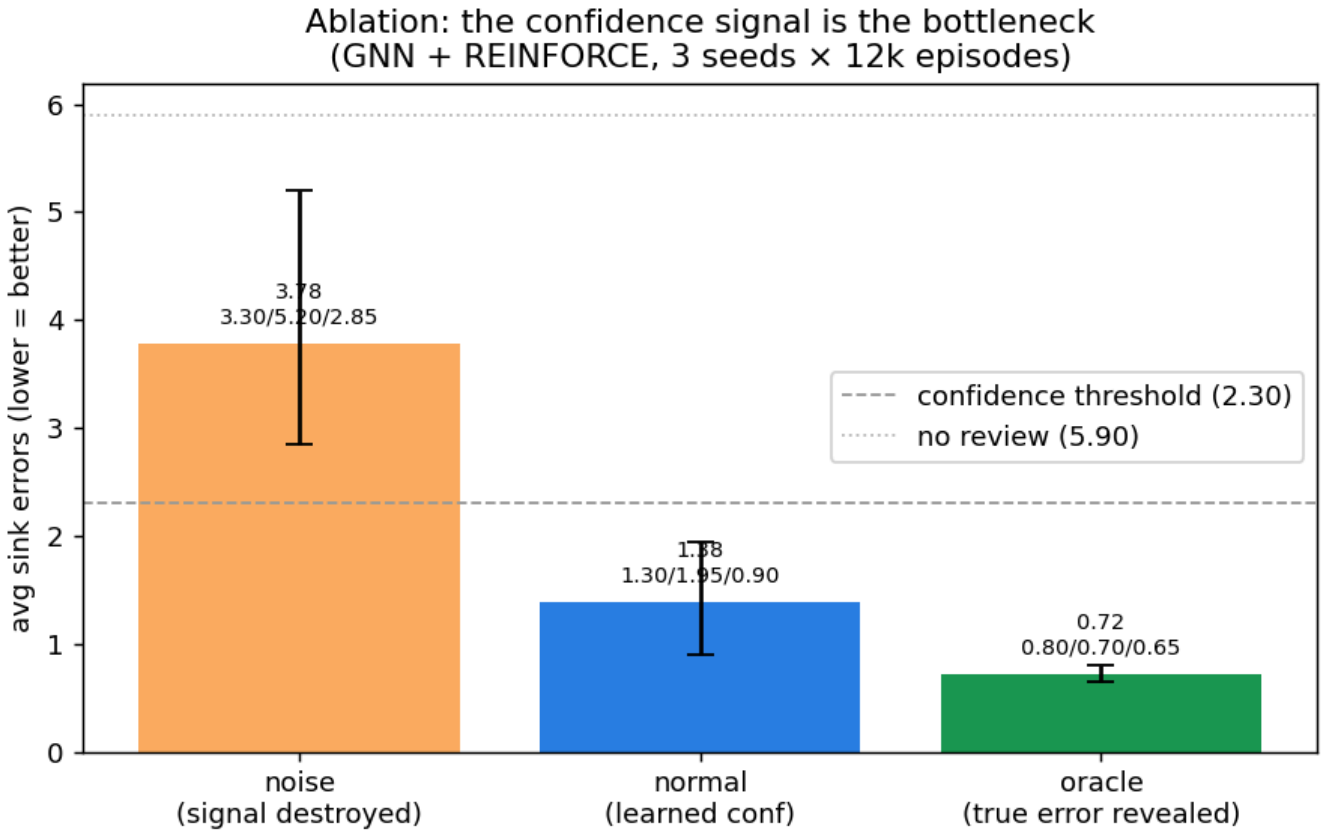


80 节点：GNN 均值 1.54 ± 0.46（最佳种子 1.00），和贪心相当，好于阈值。DQN 退化。

方法	结论错误（80 节点）
不审	5.90
置信度阈值	2.30
结构贪心	1.80
REINFORCE (MLP)	1.40
PPO (MLP)	1.60
GNN + REINFORCE	**1.54 ± 0.46**
DQN	5.10（退化）
Oracle	0.00

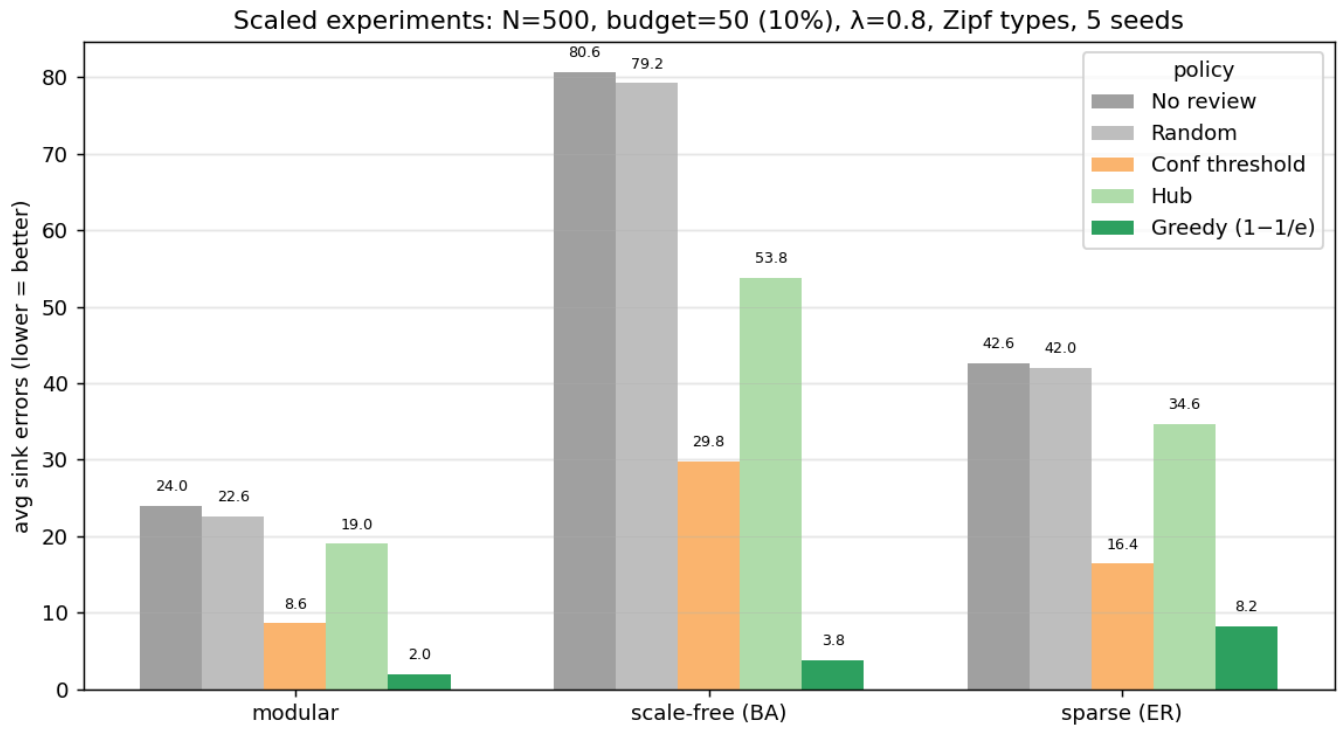


学习曲线：奖励从随机（约 −9）爬到接近 0。



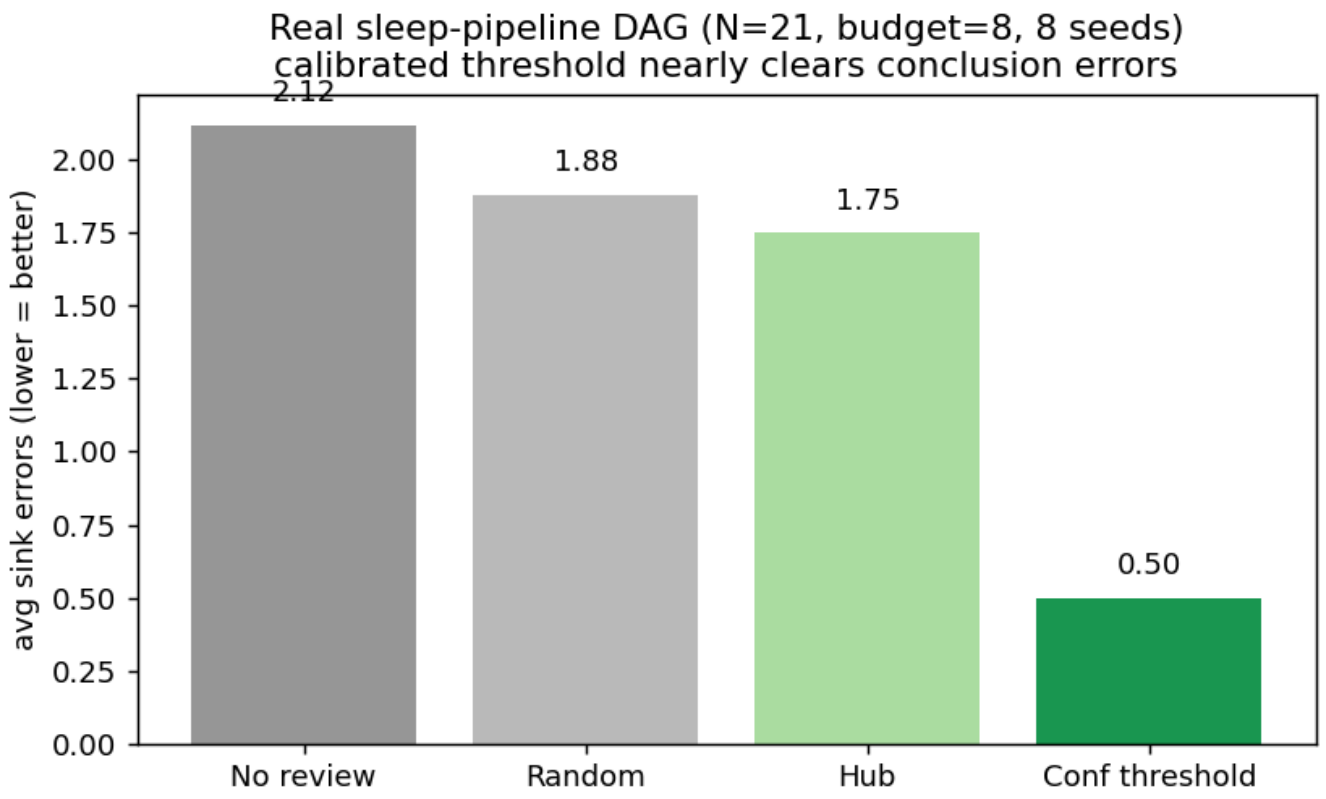
消融：打掉置信度信号 → 比阈值还差；给完美信号 → 0.72。剩下的误差住在预测器里，不在策略里。

喂什么置信度	结论错误
噪声（信号毁掉）	3.78
正常（学到的信号）	1.38
上帝视角（真错）	0.72



放大到 500 节点（模块化 / 无标度 / 稀疏）：贪心影响最大化 81→3.8（无标度）。这批是贪心，不是 RL。

图族	不审	阈值	贪心
模块化	24.0	8.6	2.0
无标度 (BA)	80.6	29.8	3.8
稀疏 (ER)	42.6	16.4	8.2



真实睡眠管道（N=21，从 SCHEMA 编码）：阈值 2.12 → 0.50。今天的数据今天就能用。

策略	结论错误
不审	2.12
随机	1.88
hub	1.75
置信度阈值	**0.50**

和 OpenAI 两个基准的关系

HealthBench（医生 rubric + worst-of-n + 共识/Hard 拆分）教我们怎么评。
BioBasicsBench（原始湿实验证据 + 错误检测 + 「证据不足」）教我们 everyday science 的失败长什么样——假设压过对照，和我们 76% order_error 同一物种。

我们采纳：偏学分收据、错误检测当一等技能、「证据不足」当显式动作、三轮评审。

我们加的：预算、依赖图、延迟到结论的惩罚。**他们没建这个。**

决策指南

如果你在什么情况	用什么
置信度信号校准得好	GNN 或结构贪心都行
置信度噪声大	**别用 RL**，静态阈值更稳
预算紧、错误按类型聚集	结构贪心（便宜、强）
能改进预测器	改置信度比改策略收益大
图很大、无标度	贪心影响最大化（守 hub）
就是我们今天的小管道	校准阈值

边界（从 SciForge 继承，不放松）

- 建议器**只读**证据图，输出排序。
- 人点「裁决」才产生收据。
- 建议永远不会自动变成裁决。
- 原始 RDS / CSV **永不进 git**。

请两位博士拍板

Maia ten Brink：睡眠 EMA 数据只做动机可以吗？真实管道 DAG（N=21）这样编码对不对？证据链边界这样划可以吗？

Zhangyang Gao：第一版 bandit 输了、重构成图上 MDP、主实验用合成图 + 真实管道小图——这个方向和范围，对 SciForge / RL 课可以吗？GNN + REINFORCE 已经跑，CMDP 软预算 naive 失败，下一步做双 critic 还是先不做？

四周排期（如果今天方向定下来）

周	做什么	谁
W1 ~11/12	冻结环境 + 基线；复现 GNN 多种子	3, 4
W2 ~11/19	双 critic CMDP 或 GNN 上 200 节点；方法表	2, 3

W3 ~11/26	对照 + 曲线 + 共识/困难拆分 + related work 定稿	4, 5
W4 ~12/03	幻灯片 + 排练 ⩾2 次	5, 全体

分工（草）

指导：Maia ten Brink, PhD（睡眠数据 / 证据链边界）· Zhangyang Gao, PhD (AI4Science, Shanghai AI Lab)

- **1** 组长 + 叙事整合
- **2** 策略梯度（REINFORCE → PPO-Lagrangian）
- **3** 环境 + GNN + DQN
- **4** 基线 + 对照实验
- **5 동채하** 文献 + 真实数据动机 + 写作 + 发表

如果被问「为什么不直接用阈值」

「阈值看不到图。结构贪心（用图）已经比阈值少 22%，证明图有价值；RL 再压 20%。而且消融说剩下的误差在置信度信号里——所以下一步是改信号，不是继续卷策略。」

ENGLISH

Which item on the evidence chain should a human review first?

STA3145 Reinforcement Learning · Group proposal (meeting one-pager)
Sleep data: 1-year EMA collaboration with Maia ten Brink (Stanford Psychophysiology Lab)
Application: SciForge, developed by Zhangyang Gao (AI4Science, Shanghai AI Lab)
2026-11-09 · 5-person team

What we build

AI already cleans sleep diaries, labels papers, runs analyses. Its outputs **depend on each other**: a flipped time becomes a wrong latency, a wrong sleep efficiency, an untrustworthy conclusion.

A human cannot check everything. We train a **read-only RL suggester**: which node to review next, so fewer errors reach the conclusion.

Machine never stamps | read-only ranking | receipt only on human verdict

Math skeleton (the RL-course main course)

1. Causal propagation (intervention on a DAG)

$$P(X_v = 0 \mid X_u = 0) = 1 - \exp(-\lambda\, w_{uv}), \quad w_{uv} \sim U(0.5, 1.5),\ \lambda = 0.8$$

Reviewing v = do$(X_v := 1)$. Causal intervention, not correlation.

2. MDP. $\mathcal{S}$ = graph knowledge + remaining budget; $\mathcal{A}$ = next node (or stop); $r_T = -\#\text{sink errors}$; $\gamma < 1$.

3. CMDP Lagrangian. $\max_\pi \min_{\lambda \geq 0} J(\pi) + \lambda\,(B - C(\pi))$. Main method today is GNN + fixed-budget REINFORCE; dual-critic CMDP is in progress.

4. Submodular greedy (1−1/e). On N=500 this greedy takes scale-free graphs from 81 to 3.8.

5. Information-gain reward (in the design, not yet run). $R = \alpha\, \Delta H_v - \beta\, \text{Cost}(v)$

6. Policy gradient (main method). $\nabla_\theta J = \mathbb{E}[\nabla_\theta \log \pi_\theta(a_t \mid s_t)\, A_t]$

GNN scorer: $h_v = \tanh(W_{\text{self}} x_v + W_{\text{neigh}} \frac{1}{|N(v)|} \sum_{u \in N(v)} x_u)$

7. Worst-of-n. One unreviewed error can invalidate a conclusion (HealthBench). noise worst-of-5 = 5.20, oracle = 0.80.

Why this is not made up

Our own data: **13,990 records / 237 people**, 75 human corrections (0.54%). Of those 75, **76% are one type** (order_error, p<0.0001).

Low error rate → reviewing everything is wasteful. High clustering → **which to review** matters more than **how many**.

What we already ran (AI-generated, teammates to reproduce)

V1 as a per-item bandit **lost to a threshold** (2.81 vs Q-learning 3.38). Diagnosis: flattening the graph leaves RL nothing to learn.

After reframing as active node selection:

Method	Sink errors (N=80)
No review	5.90
Confidence threshold	2.30
Structural greedy	1.80
REINFORCE (MLP)	1.40
PPO (MLP)	1.60
GNN + REINFORCE	1.54 ± 0.46
DQN	5.10 (degenerate)
Oracle	0.00

Family (N=500, greedy)	No review	Threshold	Greedy
Modular	24.0	8.6	2.0
Scale-free (BA)	80.6	29.8	3.8
Sparse (ER)	42.6	16.4	8.2

Real pipeline (N=21)	Sink errors
No review	2.12
Confidence threshold	0.50

Boundaries (inherited from SciForge)

- Suggester is **read-only** on the evidence graph.
- A receipt exists only when a human clicks "verdict."
- Raw RDS / CSV **never enters git**.

Ask the two PhDs

Maia ten Brink: Is it OK that sleep EMA data is motivation only? Is the N=21 real pipeline DAG encoded correctly? Are the evidence-chain boundaries right?

Zhangyang Gao: V1 bandit lost; we reframed to a graph MDP; main experiment is synthetic + a small real pipeline. Is this direction OK for SciForge / the RL course? GNN + REINFORCE already runs; naive CMDP fails; dual critic next, or wait?

Four-week plan

Week	Build	Who
W1 ~11/12	Freeze env + baselines; reproduce GNN multi-seed	3, 4
W2 ~11/19	Dual-critic CMDP or GNN on 200 nodes; method table	2, 3
W3 ~11/26	Controls + curves + consensus/hard split + related work	4, 5
W4 ~12/03	Slides + ⩾2 rehearsals	5, all

Team (draft)

Advisors: Maia ten Brink, PhD (sleep data / evidence-chain boundaries) · Zhangyang Gao, PhD (AI4Science, Shanghai AI Lab)

- **1** PM + narrative
- **2** Policy gradient (REINFORCE → PPO-Lagrangian)
- **3** Environment + GNN + DQN
- **4** Baselines + controls
- **5 동채하** Literature + real-data motivation + writing + presenting

If asked "why not just the threshold"

"The threshold cannot see the graph. Structural greedy (which uses the graph) already beats the threshold by 22%, proving the graph has value; RL adds another 20%. The ablation says the remaining error lives in the confidence signal — so the next step is the signal, not more policy tuning."

한국어

증거 사슬 위에서, 사람은 어느 항목을 먼저 검토해야 하는가?

STA3145 강화학습 · 팀 제안 (회의용)
수면 데이터: Maia ten Brink(Stanford Psychophysiology Lab)와 1년 협업 EMA
응용 대상: SciForge(Zhangyang Gao 개발, AI4Science, Shanghai AI Lab)
2026-11-09 · 5인 팀

우리가 만드는 것

AI가 이미 수면 일기를 정제하고, 문헌에 라벨을 달고, 분석을 돌립니다. 그 출력은 **서로 의존**합니다: 시간이 반대로 쓰이면 잠복기가 틀리고, 수면 효율이 틀리고, 결론이 믿을 수 없게 됩니다.

사람이 전부 확인할 수는 없습니다. 강화학습으로 **읽기 전용 제안기**를 학습합니다: 다음에 어떤 노드를 검토할지, 결론에 도달하는 오류를 줄이기 위해서.

기계는 도장을 찍지 않음 | 읽기 전용 순위 | 사람이 판정해야 영수증

수학 골격 (RL 수업의 메인)

1. 인과 전파 (DAG 개입)

$$P(X_v = 0 \mid X_u = 0) = 1 - \exp(-\lambda\, w_{uv}), \quad w_{uv} \sim U(0.5, 1.5),\ \lambda = 0.8$$

노드 v 검토 = do$(X_v := 1)$. 인과 개입이지 상관이 아닙니다.

2. MDP. $\mathcal{S}$ = 그래프 지식 + 잔여 예산; $\mathcal{A}$ = 다음 노드(또는 stop); $r_T = -\#\text{sink}$ 오류; $\gamma < 1$.

3. CMDP 라그랑지안. $\max_{\pi} \min_{\lambda \geq 0} J(\pi) + \lambda\,(B - C(\pi))$. 오늘 주 방법은 GNN + 고정 예산 REINFORCE; 이중 critic CMDP는 진행 중.

4. 준모듈러 탐욕 (1−1/e). N=500에서 이 탐욕은 스케일프리 그래프를 81 → 3.8으로 만듭니다.

5. 정보 이득 보상 (설계, 아직 미실행). $R = \alpha\,\Delta H_v - \beta\,\mathrm{Cost}(v)$

6. 정책 경사 (주 방법). $\nabla_\theta J = \mathbb{E}[\nabla_\theta \log \pi_\theta(a_t \mid s_t)\, A_t]$

GNN 점수기: $h_v = \tanh(W_{\text{self}} x_v + W_{\text{neigh}} \frac{1}{|N(v)|} \sum_{u \in N(v)} x_u)$

7. worst-of-n. 검토 안 된 오류 하나가 결론을 무효화할 수 있습니다(HealthBench). noise worst-of-5 = 5.20, oracle = 0.80.

이것이 만들어진 게 아닌 이유

우리 데이터: **13,990 기록 / 237명**, 75건 사람 정정(0.54%). 그 75건 중 **76%가 한 유형** (order_error, p<0.0001).

오류율이 낮아 전체 검토는 비효율적입니다. 오류가 강하게 뭉쳐 있어 **무엇을 검토하느냐**가 **얼마나 검토하느냐**보다 중요합니다.

이미 실행된 것 (AI 생성, 팀원 재현 필요)

1판 밴딧은 **임계값에 졌습니다** (2.81 vs Q-러닝 3.38). 진단: 항목별 검토는 그래프를 평평하게 만듭니다.

그래프 위 능동적 노드 선택으로 재구성한 뒤:

방법	sink 오류 (N=80)
무검토	5.90
신뢰도 임계값	2.30
구조적 그리디	1.80
REINFORCE (MLP)	1.40
PPO (MLP)	1.60

GNN + REINFORCE	1.54 ± 0.46
DQN	5.10 (퇴화)
Oracle	0.00

족 (N=500, 탐욕)	무검토	임계값	탐욕
모듈형	24.0	8.6	2.0
스케일프리 (BA)	80.6	29.8	3.8
희소 (ER)	42.6	16.4	8.2

실제 파이프라인 (N=21)	sink 오류
무검토	2.12
신뢰도 임계값	0.50

경계 (SciForge에서 상속)

- 제안기는 증거 그래프를 **읽기 전용**으로 봅니다.
- 사람이 "판정"을 클릭해야 영수증이 됩니다.
- 원시 RDS / CSV는 **git에 들어가지 않습니다**.

두 박사에게 묻습니다

Maia ten Brink: 수면 EMA 데이터가 동기로만 쓰여도 되나요? N=21 실제 파이프라인 DAG 인코딩이 맞나요? 증거 사슬 경계가 맞나요?

Zhangyang Gao: 1판 밴딧이 졌고, 그래프 MDP로 재구성했고, 주요 실험은 합성 + 작은 실제 파이프라인입니다. 이 방향이 SciForge / RL 수업에 맞나요? GNN + REINFORCE는 이미 돌아가고, naive CMDP는 실패했습니다. 이중 critic을 다음에 만들까요, 기다릴까요?

4주 계획

주	만드는 것	누구
W1 ~11/12	환경 + 베이스라인 고정; GNN 다중 시드 재현	3, 4

W2 ~11/19	이중 critic CMDP 또는 200노드 GNN; 방법 표	2, 3
W3 ~11/26	대조 + 곡선 + 합의/하드 분할 + 관련 연구	4, 5
W4 ~12/03	슬라이드 + 리허설 ⩾2회	5, 전체

팀 (초안)

지도: Maia ten Brink, PhD (수면 데이터 / 증거 사슬 경계) · Zhangyang Gao, PhD (AI4Science, Shanghai AI Lab)

- **1** PM + 내러티브
- **2** 정책 경사 (REINFORCE → PPO-Lagrangian)
- **3** 환경 + GNN + DQN
- **4** 베이스라인 + 대조
- **5 동채하** 문헌 + 실데이터 동기 + 집필 + 발표

"왜 바로 임계값을 안 쓰나요"라고 물으면

"임계값은 그래프를 못 봅니다. 그래프를 쓰는 탐욕이 이미 임계값보다 22% 낫다는 걸 증명했고, RL이 추가로 20% 더 줄입니다. 그리고 소거는 남은 오류가 신뢰도 신호에 있다고 말합니다 — 다음 단계는 정책이 아니라 신호입니다."

자세한 버전: PROJECT_EN.md · PROJECT_KO.md · PROJECT_CN.md · IMPLEMENTATION_SPEC.md · _KO.md · _CN.md · EVIDENCE_CHAIN_DESIGN.md · _CN.md
코드와 그림: github.com/cyracaid/rl-oversight-dag