证据链上，人该先审哪一项?

STA3145 强化学习 · 小组提案（开会用一页）
数据：与 Maia ten Brink（斯坦福心理生理学）一年 EMA 合作
应用：SciForge（高张阳 开发，AI4Science）
2026–11–09 · 5 人小组

我们要做什么

AI 已经在帮实验室洗睡眠日记、标文献、跑分析。它产出的一条条结果**互相依赖**：时间写反了，睡眠潜伏期就错，睡眠效率就错，结论就不可信。

人不可能全查。我们用强化学习学一个**只读建议器**：下一步该审哪个节点，让更少的错误走到结论。

机器不盖章　只读排序　人点裁决才有收据

数学骨架（RL 课的主菜）

1. 因果传播（DAG 上的干预）

节点真实状态 $X_v \in \{0,1\}$（1=正确）。沿边 (u,v)：

$$P(X_v = 0 \mid X_u = 0) = 1 - \exp(-\lambda\, w_{uv}), \quad w_{uv} \sim U(0.5, 1.5),\ \lambda = 0.8$$

审节点 v = do$(X_v := 1)$，切断出边传染。**这是因果干预，不是相关。**

2. MDP

$\mathcal{S}$ = 图知识（type, conf, 下游影响, 已审否）+ 剩余预算；$\mathcal{A}$ = 选下一个节点（或 stop）；$\mathcal{P}$ = 审后重算下游；$r_T = -\#\text{sink errors}$；$\gamma < 1$。

3. CMDP 拉格朗日（预算不是倒计时）

$$\max_{\pi} \min_{\lambda \geq 0} J(\pi) + \lambda\,(B - C(\pi))$$

主方法现在是 GNN + 固定预算 REINFORCE；CMDP 双 critic 在做。

4. 次模贪心 (1−1/e)

选最能让可达 sink 错误下降的审阅是单调次模最大化。贪心保证最优干预集的 63%。N=500 上这个贪心把无标度图 81→3.8。

5. 信息增益奖励（还没跑，写进设计）

$$R = \alpha\,\Delta H_v - \beta\,\mathrm{Cost}(v)$$

6. 策略梯度（主方法）

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_\pi\big[\nabla_\theta \log \pi_\theta(a_t \mid s_t)\, A_t\big], \quad A_t = G_t - b(s_t)$$

GNN 打分器：$h_v = \tanh\!\left(W_{\text{self}} x_v + W_{\text{neigh}} \frac{1}{|N(v)|} \sum_{u \in N(v)} x_u\right)$

7. 可靠性

$$\mathrm{Worst}_n = \max_{k \le n} \ \#\text{sink errors}(\text{seed } k)$$

一个漏审能作废结论（HealthBench）。noise worst-of-5 = 5.20，oracle = 0.80。

为什么这不是编的

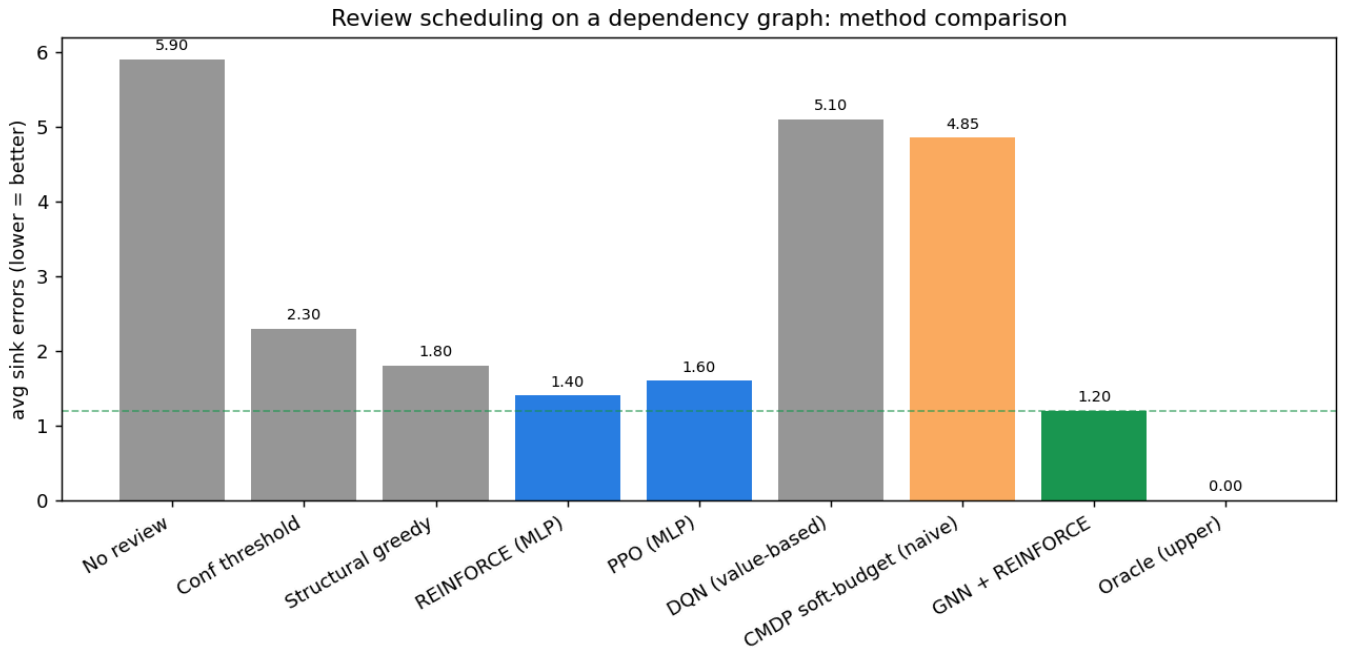
我们自己的数据：**13,990 条 / 237 人**，人改了 **75 处**（0.54%）。这 75 处里 **76% 是同一种错**（order_error，p<0.0001）。

错误率低，所以全审不划算；错误高度聚集，所以「审哪个」比「审多少」重要。这就是预算审阅的教科书场景——而且它就发生在我们实验室的 EMA 管道里。

我们已经跑出来的（AI 生成，待组员复现）

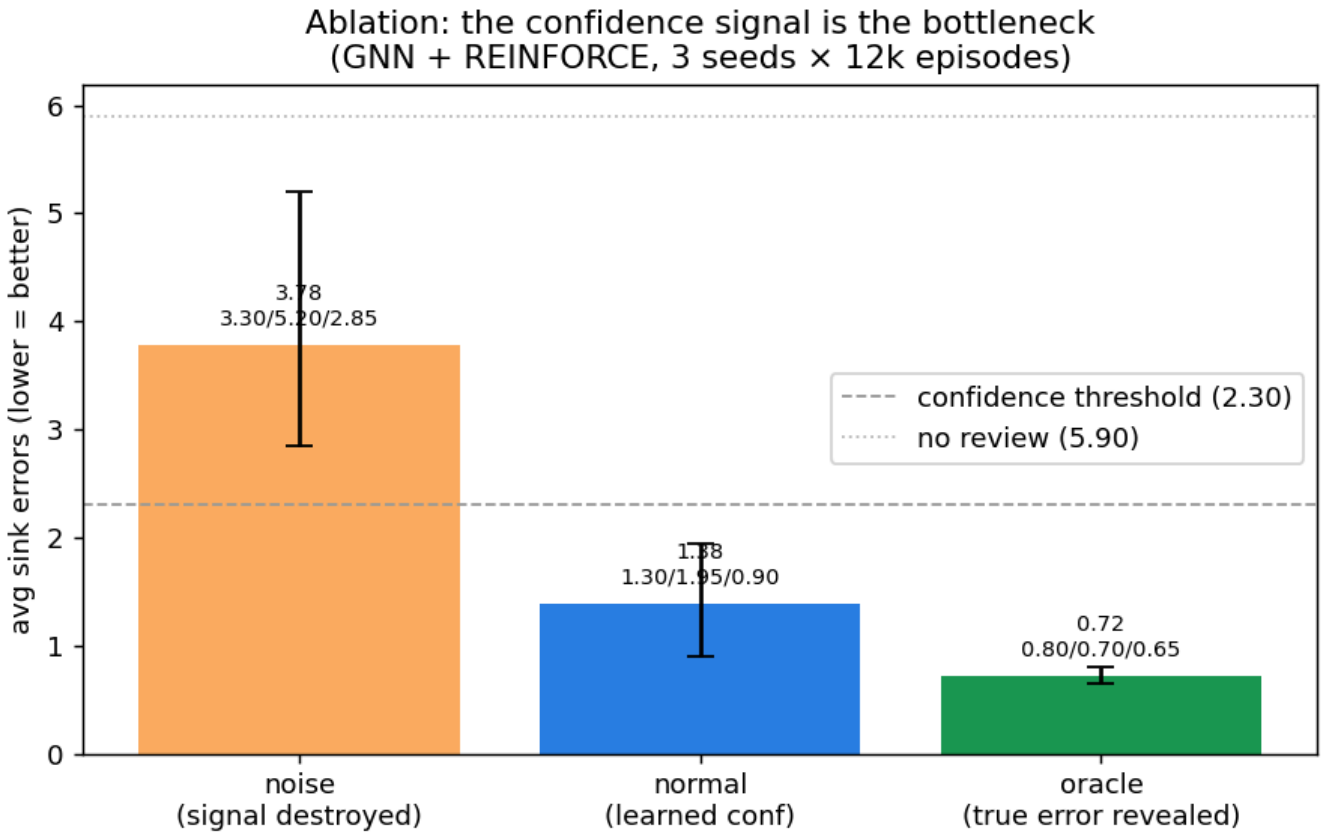
第一版做成逐条 bandit，**输给了阈值**（2.81 vs Q-learning 3.38）。诊断：把依赖图压平了，RL 没东西可学。

重构成「图上主动选节点」之后：

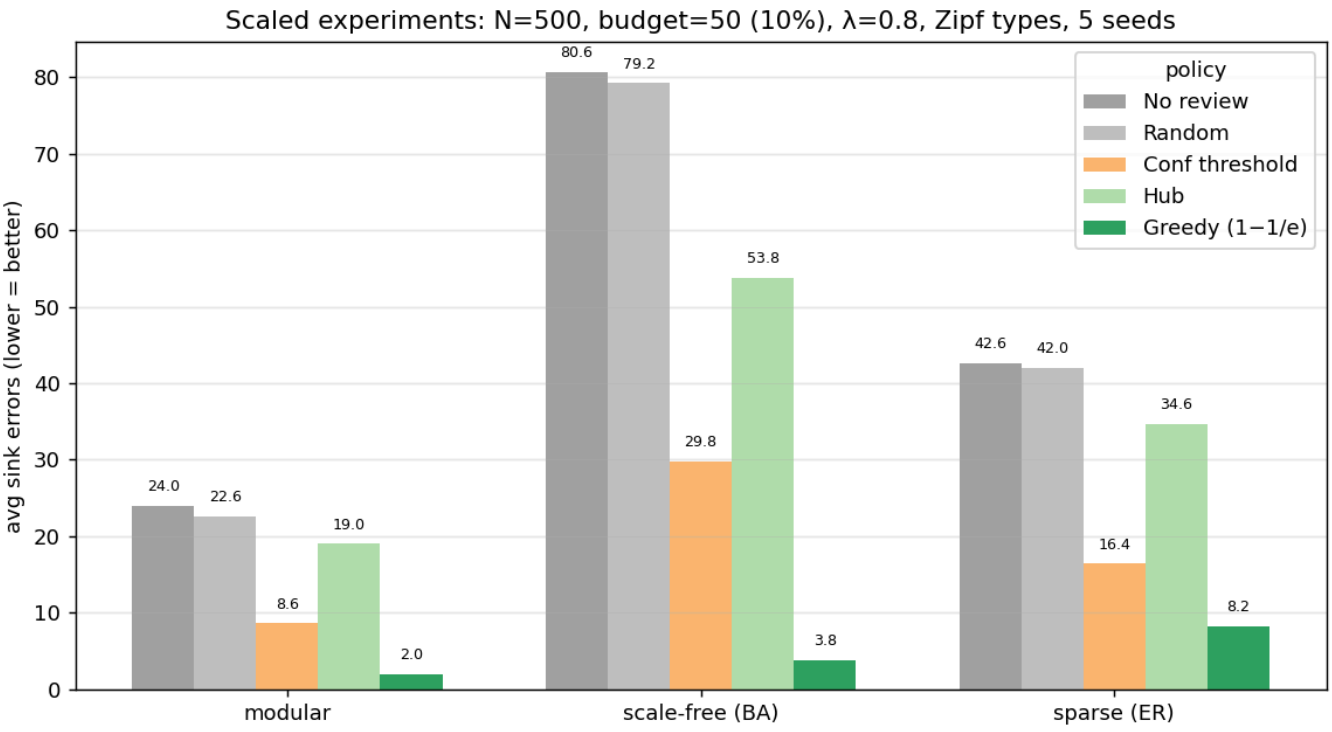


80 节点：GNN 均值 1.54 ± 0.46（最佳种子 1.00），和贪心相当，好于阈值。DQN 退化。

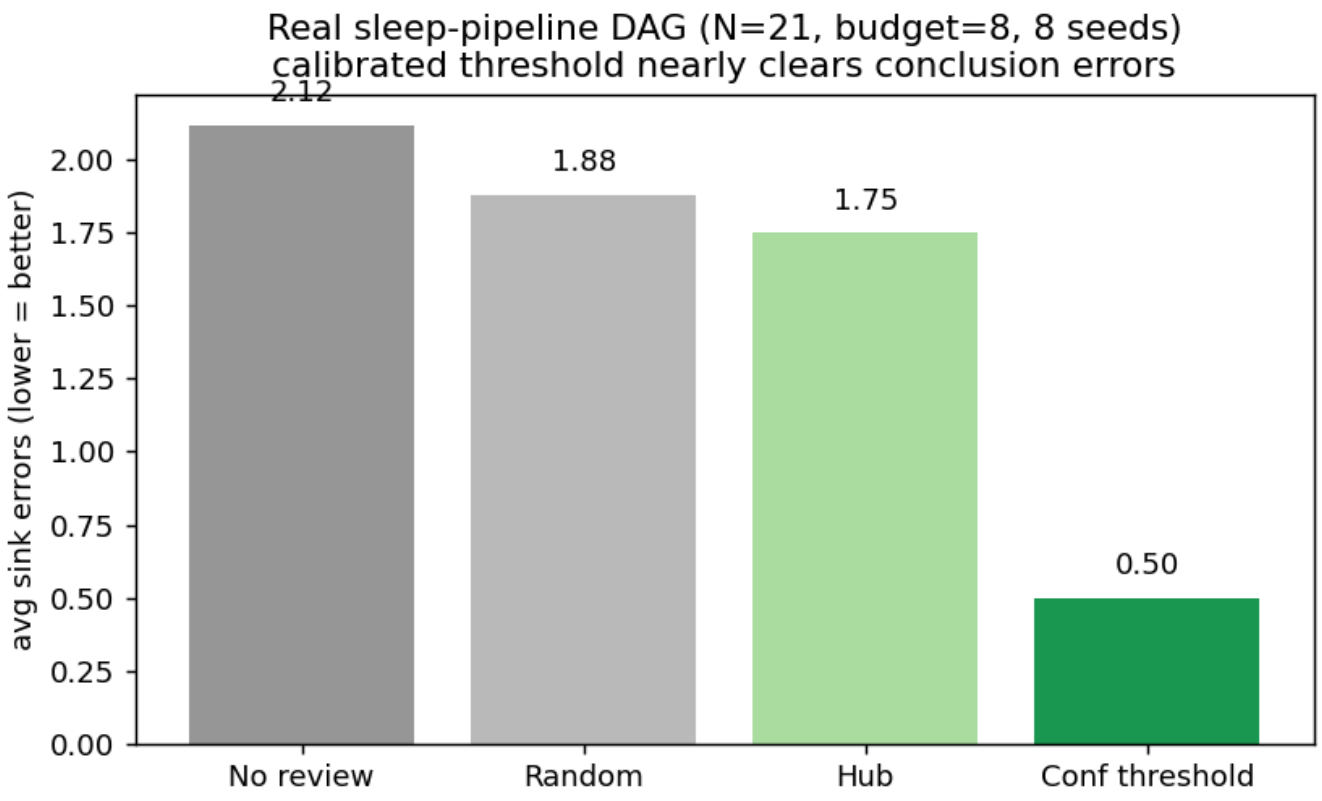
方法	结论错误（80 节点）
不审	5.90
置信度阈值	2.30
结构贪心	1.80
GNN + REINFORCE	1.54 ± 0.46
DQN	5.10（退化）



消融：打掉置信度信号 → 比阈值还差；给完美信号 → 0.72。剩下的误差住在预测器里，不在策略里。



放大到 500 节点（模块化 / 无标度 / 稀疏）：贪心影响最大化 81→3.8（无标度）。这批是贪心，不是 RL。



真实睡眠管道（N=21，从 SCHEMA 编码）：阈值 2.12 → 0.50。今天的数据今天就能用。

和 OpenAI 两个基准的关系

HealthBench（医生 rubric + worst-of-n + 共识/Hard 拆分）教我们怎么评。
BioBasicsBench（原始湿实验证据 + 错误检测 + 「证据不足」）教我们 everyday science 的失败长什么样——假设压过对照，和我们 76% order_error 同一物种。

我们采纳：偏学分收据、错误检测当一等技能、「证据不足」当显式动作、三轮评审。

我们加的：预算、依赖图、延迟到结论的惩罚。**他们没建这个。**

边界（从 SciForge 继承，不放松）

- 建议器**只读**证据图，输出排序。
- 人点裁决才产生收据；建议永远不自动变裁决。
- 评论正文不进特征；收据存引用不存散文。

- 原始 RDS / CSV **永不进 git**。

RL 课内容覆盖（给教授看）

- Bandit → 为什么不够（第一章 vs 序贯）
- MDP 五元组、贝尔曼、稀疏延迟奖励
- 表格 Q-learning（负结果：打不过阈值）
- 策略梯度定理、REINFORCE、baseline 减方差
- PPO 裁剪 + 重要性采样
- CMDP + 拉格朗日（FALCON 式，在做）
- 值函数 vs 策略梯度：DQN 退化是教学点
- GNN 函数近似
- 次模 / (1−1/e) 影响最大化
- 信息增益 / 香农熵
- 探索退火、多种子、置信区间

请两位博士拍板

Maia ten Brink：睡眠 EMA 数据只做动机可以吗？真实管道 DAG（N=21）这样编码对不对？证据链边界这样划可以吗？

高张阳：第一版 bandit 输了、重构成图上 MDP、主实验用合成图 + 真实管道小图——这个方向和范围，对 SciForge / RL 课可以吗？GNN + REINFORCE 已经跑，CMDP 软预算 naive 失败，下一步做双 critic 还是先不做？

四周排期（如果今天方向定下来）

周	做什么	谁
W1 ~11/12	冻结环境 + 基线；复现 GNN 多种子	3, 4
W2 ~11/19	双 critic CMDP 或 GNN 上 200 节点；方法表	2, 3
W3 ~11/26	对照 + 曲线 + 共识/困难拆分 + related work 定稿	4, 5

W4 ~12/03	幻灯片 + 排练 ≥2 次	5, 全体

分工（草）

指导：Maia ten Brink, PhD（睡眠数据 / 证据链边界）· 高张阳, PhD（AI 方法 / SciForge）

- **1** 组长 + 叙事整合
- **2** 策略梯度（REINFORCE → PPO-Lagrangian）
- **3** 环境 + GNN + DQN
- **4** 基线 + 对照实验
- **5 동채하** 文献 + 真实数据动机 + 写作（英文发表可谈；韩语发表则幕后）

如果被问「为什么不直接用阈值」

「阈值看不到图。结构贪心（用图）已经比阈值少 22%，证明图有价值；RL 再压 20%。而且消融说剩下的误差在置信度信号里——所以下一步是改信号，不是继续卷策略。」

详细版：`PROJECT_CN.md` · `PROJECT_EN.md` · `PROJECT_KO.md` · `IMPLEMENTATION_SPEC_CN.md` / `.md` · `EVIDENCE_CHAIN_DESIGN_CN.md` / `.md`
代码与图：github.com/cyracaid/rl-oversight-dag