该先审哪一项？ / Which item first? / 어느 항목 먼저?

STA3145 Reinforcement Learning · Group project · 2026–11

Sleep data: 1–year EMA with Maia ten Brink (Stanford Psychophysiology Lab) · Application: SciForge (Zhangyang Gao, AI4Science, Shanghai AI Lab)

0 一句话

AI 帮实验室洗日记、标文献、跑分析。结果**互相依赖**：时间反了，潜伏期错，效率错，结论不可信。

人不可能全查。我们用 RL 学一个**只读建议器**：下一步审哪个节点，让更少错误走到结论。

机器不盖章　只读排序　人点裁决才有收据

1 为什么是真的

我们实验室睡眠日记：**13,990 条 / 237 人**。人只改了 **75 处**（0.54%）。

这 75 处 **76% 是同一种错**（order_error，p<0.0001）。

错不会待在原地：时间错 → 潜伏期错 → 效率错 → 结论错。

> 「审多少」不如「审什么」。预算只有一点点，花在 76% 那种错的上游更值。

2 走过的弯路

第一版做成逐条 bandit。**阈值赢了 Q-learning**（2.81 vs 3.38）。

原因：逐条审把依赖图压平了，RL 没东西可学。76% 一种错，最优策略退化成 if 规则。

> 这个失败没藏，它是重构的理由。

3 重构：下一个审哪个

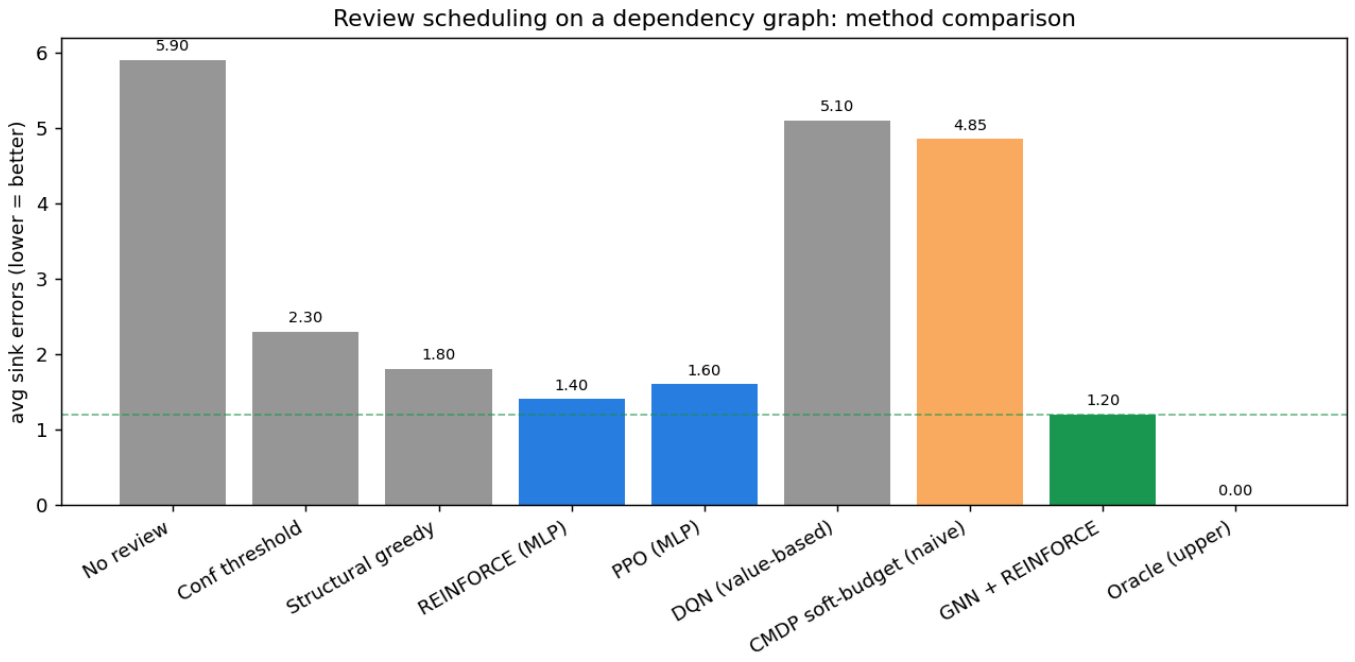
证据画成有向图。智能体每步选一个节点审。审对了下游跟着变。

真 MDP：状态有图和剩余预算，奖励只在最后。

```
前端    划线提问 / 日记行审阅          → 审阅痕迹（不是收据）
          ↓
审阅层   GNN / 贪心 / 阈值 建议器       → 「先审这几个」(只读)
          ↓  人点「裁决」
后端     SciForge 证据 DAG + 收据       → 机器不盖章，append-only
```

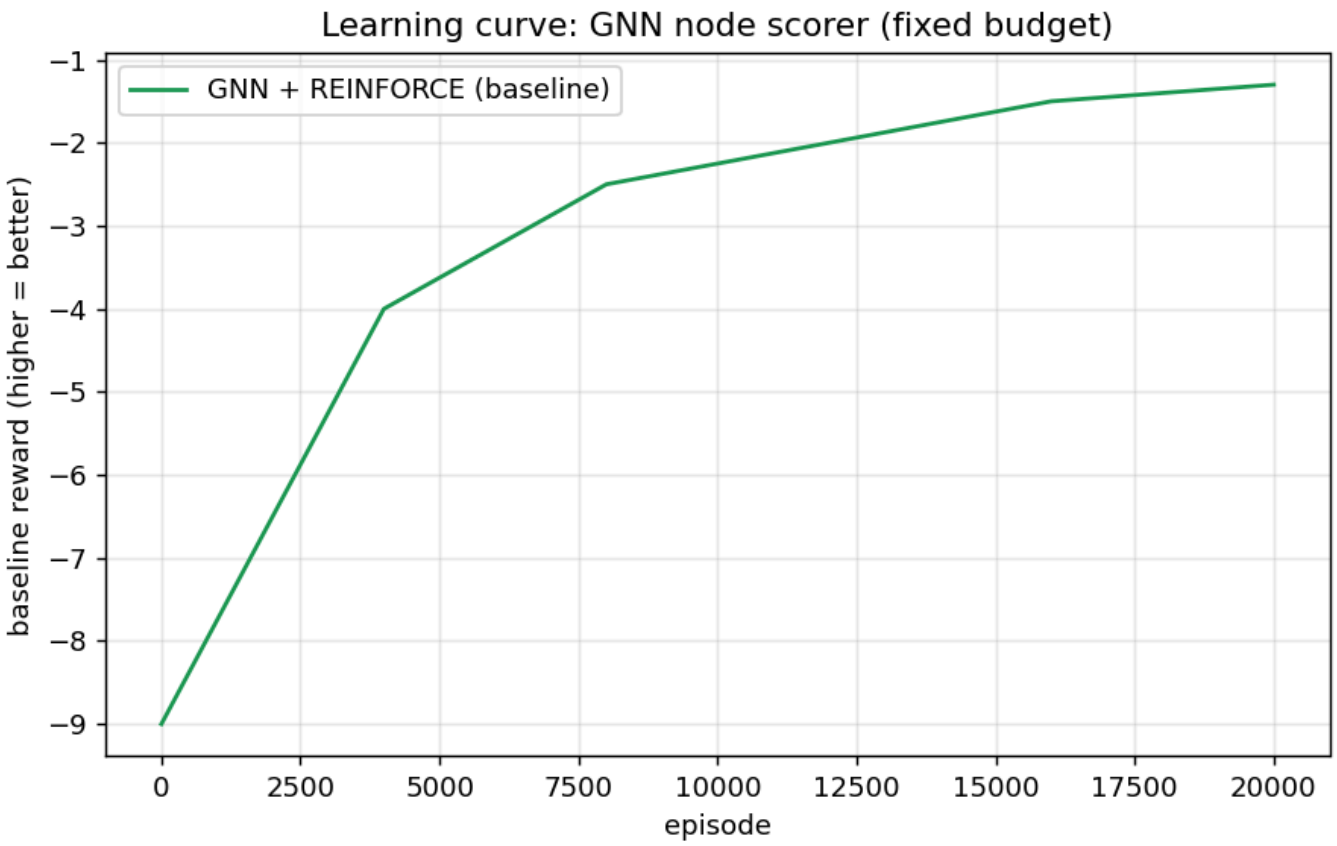
4 结果

数字 = 到达结论的错误数，越低越好。



80 节点。GNN 是 5 种子均值，不是单次最好的 1.20。

方法	结论错误
不审	5.90
置信度阈值	2.30
结构贪心	1.80
REINFORCE (MLP)	1.40
PPO (MLP)	1.60
GNN + REINFORCE	**1.54 ± 0.46**
DQN	5.10（退化）
Oracle	0.00



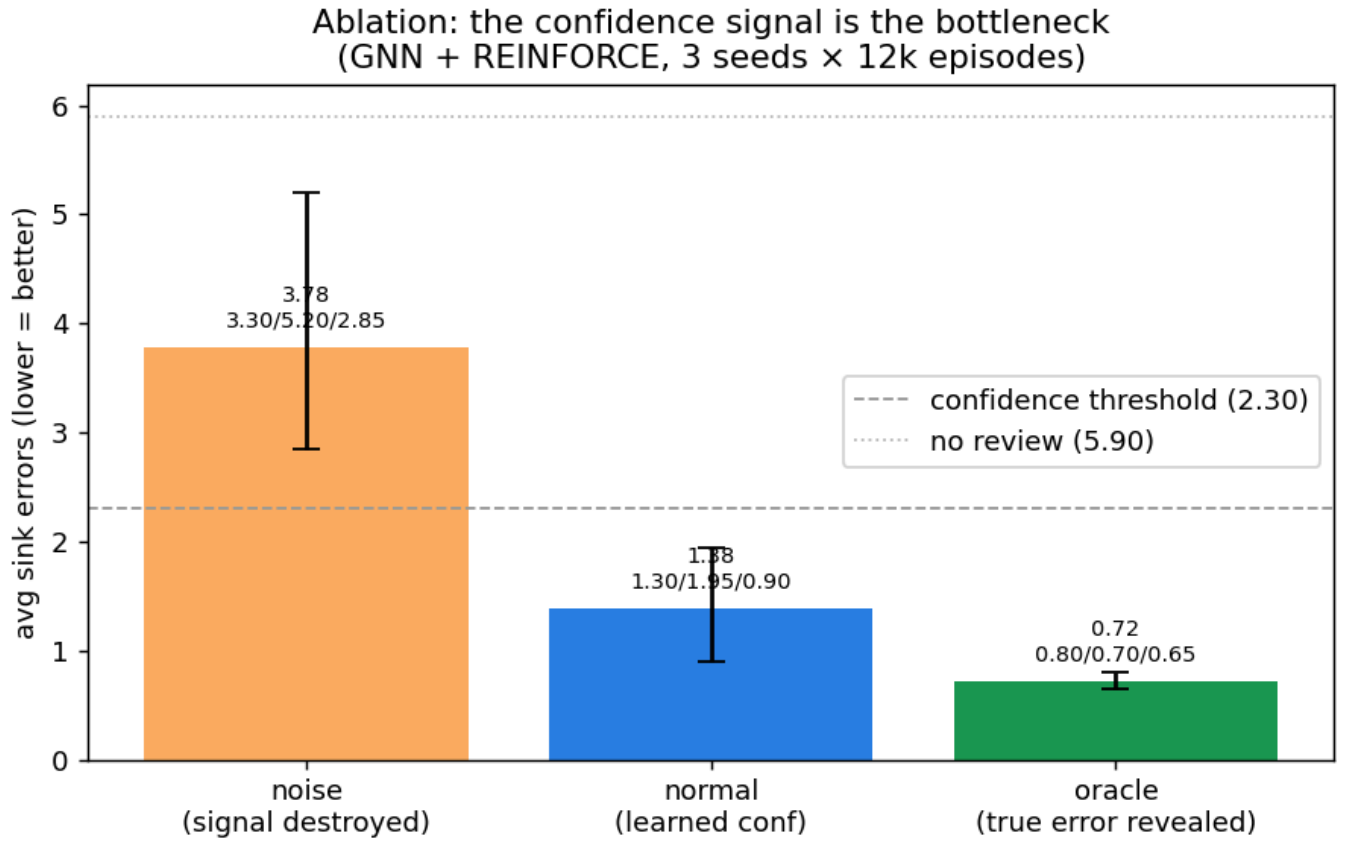
学习曲线：奖励从随机（约 −9）爬向 0。

诚实：GNN 均值 1.54 和贪心（1.80）、MLP REINFORCE（1.40）**相当**，不是稳定碾压。最佳种子 1.00 有空间，要看多种子。

DQN 退化——稀疏终局奖励喂不饱价值函数。**这里该用策略梯度**。

5 消融：剩下的误差在置信度里

同样 GNN，换三种置信度：



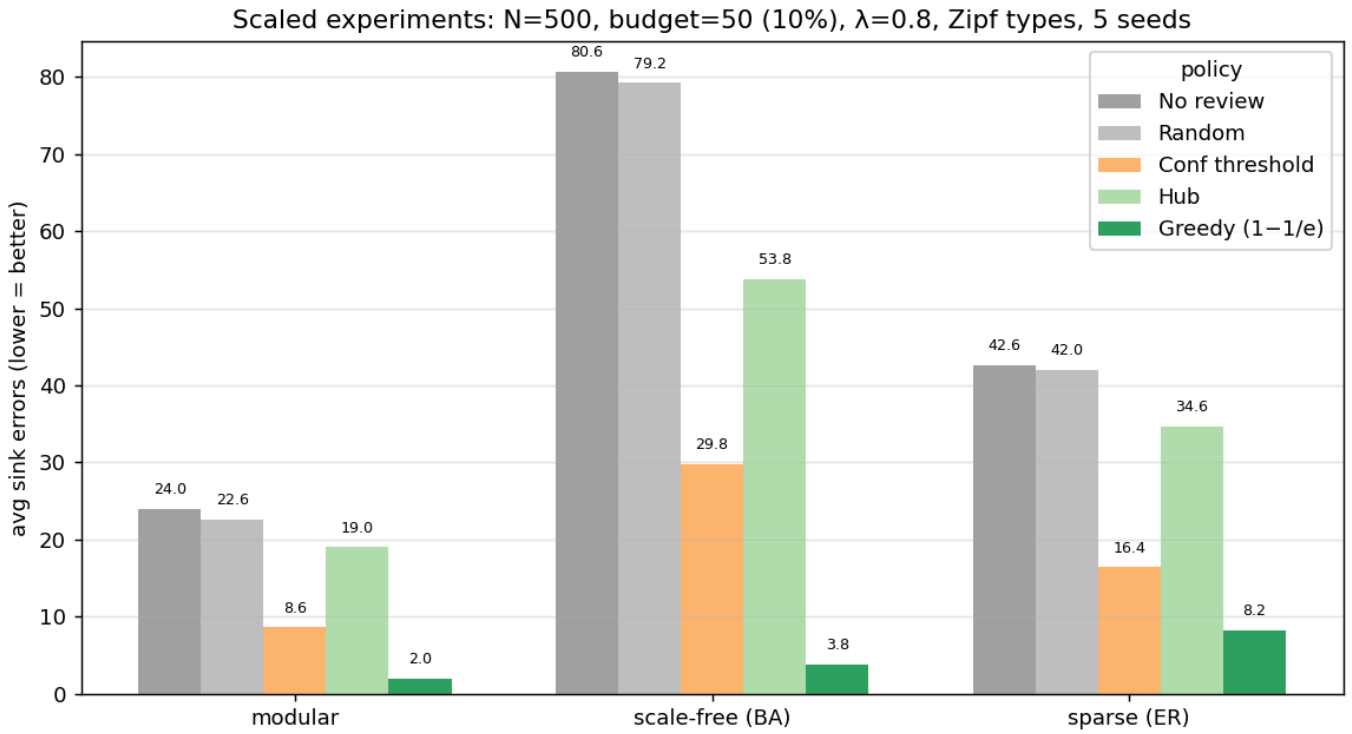
打掉信号 → 比阈值还差；完美信号 → 0.72。瓶颈在预测器，不在调度器。

置信度	结论错误
噪声	3.78
正常	1.38
上帝视角	0.72

> 别卷调度算法。**把置信度信号做好，收益更大。**剩余误差住在预测器里。

6 放大：500 节点

三种 500 节点图：模块化、无标度（少数 hub）、稀疏随机。预算 50（10%）。



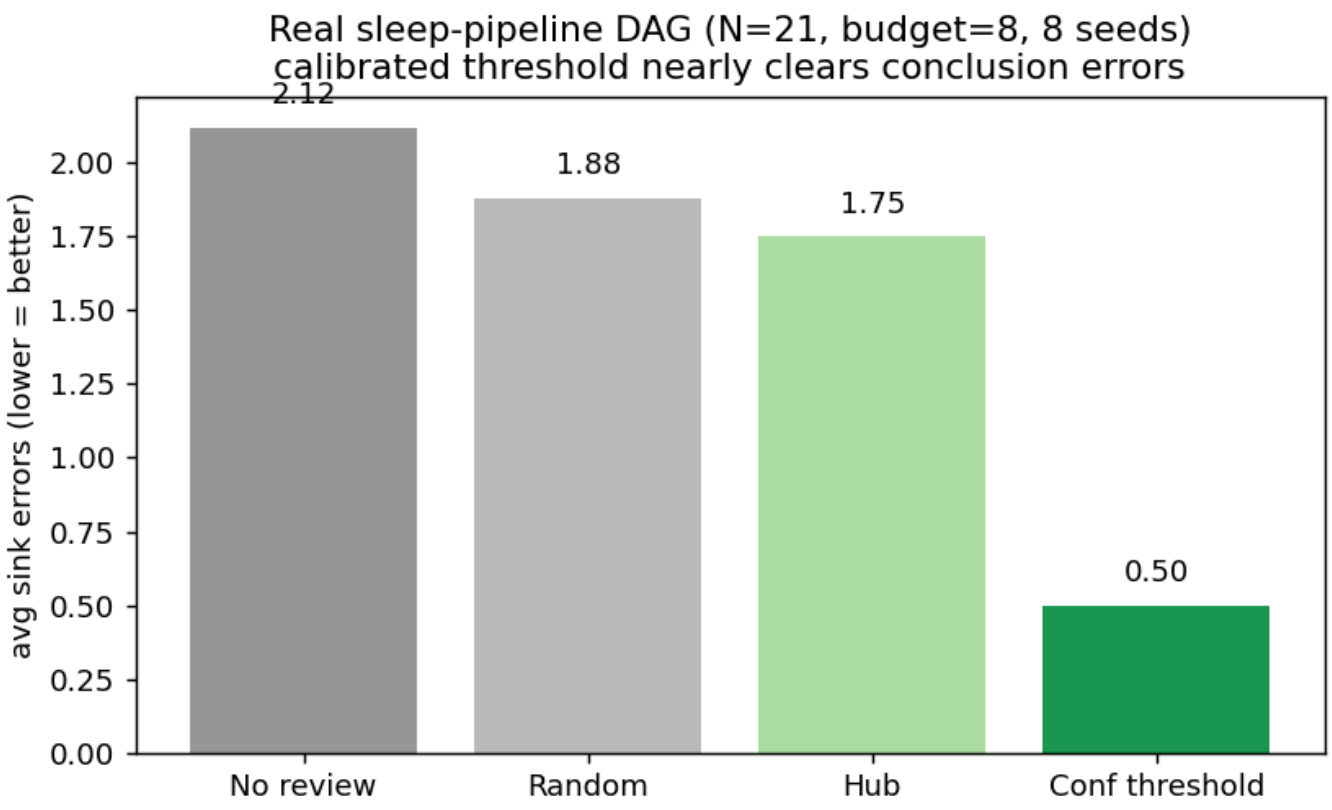
贪心影响最大化几乎清空三种图。无标度 81 → 3.8（降 95%）。

图族	不审	阈值	贪心
模块化	24.0	8.6	2.0
无标度 (BA)	80.6	29.8	3.8
稀疏 (ER)	42.6	16.4	8.2

诚实：这批 500 节点数字是**贪心启发式，不是 RL**。说明问题在规模下依然有趣，贪心是必须打赢的基线。

7 我们自己的管道

splsleep SCHEMA 编成 21 节点真图：原始时间 → 差值 → SOL/WASO/TST/效率 → 结论。



今天的数据管道上，校准阈值把结论错误从 2.12 降到 0.50。

策略	结论错误
不审	2.12
置信度阈值	0.50
hub	1.75

> 500 节点说「图变大怎么办」。这 21 节点说**今天的数据怎么办**：校准阈值就够。

8 OpenAI 两个基准

HealthBench：医生 rubric + worst-of-n + 共识/Hard。**BioBasicsBench**：原始湿实验证据 + 错误检测 + 「证据不足」。失败模式：**假设压过对照**，和我们 76% order_error 同一物种。

采纳：偏学分收据、错误检测当一等技能、「证据不足」当显式动作。

加的：预算、依赖图、延迟到结论的惩罚。**他们没建。**

9 决策指南

情况	用什么
置信度校准好	GNN 或结构贪心
置信度噪声大	**别用 RL**，静态阈值更稳
预算紧、错误按类型聚集	结构贪心
能改进预测器	改置信度比改策略收益大
图很大、无标度	贪心影响最大化
今天的小管道	校准阈值

10 机器不盖章

- 建议器**只读**证据图，输出排序。
- 人点「裁决」才产生收据。
- 建议永远不自动变裁决。
- 原始 RDS / CSV **不进 git**。

11 分工

指导：Maia ten Brink, PhD（睡眠数据 / 证据链边界）· Zhangyang Gao, PhD (AI4Science, Shanghai AI Lab)

- **1** 组长 + 叙事
- **2** 策略梯度（REINFORCE → PPO–Lagrangian）

- **3** 环境 + GNN + DQN
- **4** 基线 + 对照
- **5 동채하** 文献 + 真实数据动机 + 写作 + 发表

Review Scheduling on a Dependency Graph · STA3145 · github.com/cyracaid/rl-oversight-dag